

Detecção de Intrusão em Redes IoT

Avaliação de Redes Neurais Sem Peso no dataset TON_IoT Telemetry
GRUPO 3

WiSARD • ClusWiSARD • BloomWiSARD • ULEEN • BTHOWeN
Comparação com baseline ML/DL de Alsaedi et al. (IEEE Access, 2020)

Agenda

01

Contexto e Motivação

Cibersegurança em IoT/IIoT e o problema de IDS

02

Dataset TON_IoT

Origem, dispositivos, ataques e distribuição

03

Redes Neurais Sem Peso

WiSARD, ClusWiSARD, BloomWiSARD, ULEEN, BTHOWeN

04

Metodologia

Pré-processamento, binarização e hiperparâmetros

05

Resultados

Treinamento, comparações com baseline

06

Conclusões

Contexto: Cibersegurança em IoT/IIoT



Superfície de Ataque

Dispositivos de baixa capacidade que impedem soluções criptográficas tradicionais.



Impacto Real

Mirai botnet e ataques a infraestruturas críticas (energia) afetando milhares de clientes.



IDS Data-Driven

Uso de telemetria de sensores para detectar manipulação de dados sensoriais.

Objetivo: avaliar Redes Neurais Sem Peso (WNN) como IDS de baixo custo computacional para IoT.

Dataset TON_IoT Telemetry

Características Gerais

- **Geração:** Testbed realista de 3 camadas (Edge-Fog-Cloud).
- **Tipo:** Telemetria de 7 sensores IoT/IIoT.
- **Rotulagem:** Binária (label) e Multi-classe (type).
- **Tamanho:** 261.119 instâncias × 17 features.

Diferencial: Une telemetria de sensores + tráfego de rede + logs de SO.

Dispositivos Avaliados

Fridge Temp. e Condição

GPS Tracker Lat. e Longitude

Garage Door Estado e Smartphone


Modbus Function Codes

Weather Pressão e Umidade

Tipos de Ataques e Distribuição

9 Tipos Avaliados

- **DoS / DDoS:** Sobrecarga de recursos.
- **Ransomware:** Criptografia maliciosa.
- **Injection:** Injeção de comandos.
- **XSS:** Cross-Site Scripting.
- **Password Cracking:** Brute-force.
- **Scanning:** Reconhecimento (Nmap).



Desbalanceamento severo: Classes raras impactam o Recall multi-classe.

Modelos WNN Avaliados

WiSARD (1984)

Modelo clássico com RAMs binárias.
Bleaching reduz colisões.

ClusWiSARD (2014)

Múltiplos discriminadores por classe para subgrupos de ataques.

BloomWiSARD (2019)

RAMs substituídas por Bloom Filters para economia de memória.

BTHOWeN (2022)

Hashed-Input otimizado. Alta eficiência em hardware customizado.

ULEEN (2023)

Ultra-Low Energy. Treino gradient-based + pruning agressivo.

Metodologia Experimental




Hiperparâmetros Utilizados

Modelo	Ano	Implementação	Endereçamento	Entrada (binarização)	Outros parâmetros	Referência
WiSARD	1984	wisardpkg (Python)	address_size = 32	Variable Thermometer ponderado, 16 bits	bleaching ativo	<i>Aleksander et al. (1984)</i>
ClusWiSARD	2014	wisardpkg (Python)	address_size = 32	Variable Thermometer ponderado, 16 bits	min_score=0.05, threshold=100, limit=20	<i>Cardoso et al. (2014)</i>
BloomWiSARD	2019	C++ (pybind11)	address_size = 16	Thermometer 16 bits/feature	bloom_capacity = 1000	<i>Santiago et al. (2020)</i>
BTHOWeN	2022	PyTorch + scripts orig.	filter_inputs = 8	Thermometer 16 bits/input	filter_entries=1024 filter_hashes=2	<i>Susskind et al. (2022)</i>
ULEEN	2023	PyTorch (gradient-based)	filter_inputs = 12	Thermometer 8 bits/input	filter_entries = 128 filter_hashes = 2	<i>Susskind et al. (2023)</i>

Resultados: Classificação Binária (F1-Score)


F1-Score Binário por Dispositivo e Modelo WNN



BloomWiSARD lidera em média ($F1 = 0,813$)


Classificação Multi-classe (F1-Score)

F1-Score Multi-classe por Dispositivo e Modelo WNN




ClusWiSARD lidera (F1 = 0,416)

Comparação com Alsaedi et al. (Weather)




WNN superam 8 dos 8 baselines · BloomWiSARD (1) e ClusWiSARD vencem todos ·

Velocidade: Tempos de Treino





BloomWiSARD: 0,14s · WiSARD: 0,64s · BTHOWeN: 14,02s · Comparação: LSTM do artigo levou 318s — BloomWiSARD é mais de 1000× mais rápido

Sensibilidade: Address Size (n-tupla) WISARD







Sensibilidade: Address Size (n-tupla) BloomWISARD

Sensibilidade ao Address Size — Weather (Binario)



Sensibilidade: Address Size (n-tupla) BTHOWeN

Sensibilidade — BTHOWeN — Weather (Binario)



Limitações e Ameaças à Validade

Desbalanceamento

Recall zero em classes raras (<2%). Problema comum a todos os modelos avaliados.

Single Split

Uso de 80/20 fixo sem cross-validation (k-fold). Possível variância não capturada.

Grid Search

Hiperparâmetros otimizados principalmente para WiSARD no Weather. Não exaustivo para todos dispositivos.

Conclusões

Competitividade

WNN são competitivas em escala individual por dispositivo ($F1 \approx 1$).

Velocidade

Treino mais de 1000x mais rápido que LSTM. Fundamental para IoT.

BloomWiSARD Clássico

Ainda domina na maioria dos cenários multi-classe e binários estáveis.

Interpretabilidade

Decisões auditáveis superam caixas-pretas (LSTM/MLP).

Trabalhos Futuros e Referências

Futuros

- Oversampling (SMOTE) para classes raras.
- Implementação em FPGA (energia real).
- Grid-search exaustivo por dispositivo.

Principais Referências

1. Alsaedi et al. (2020). TON_IoT Dataset. IEEE Access.
2. Aleksander et al. (1984). WISARD. Sensor Review.
3. Santiago et al. (2020). BloomWiSARD. ESANN.
4. Susskind et al. (2023). ULEEN. ACM TACO.

Obrigado!

PESC / COPPE / UFRJ •
2026

Redes Neurais Sem Peso (WNN)

Princípio de Funcionamento

- 1 **Binarização:** Features viram vetores de bits.
- 2 **Tuplas:** Bits endereçam RAMs.
- 3 **Memorização:** Escreve-se '1' na RAM durante o treino.
- 4 **Classificação:** Maior score de RAMs ativadas vence.

.

Vantagens para IoT

- ⚡ Treino ultra-rápido (one-shot).
- 🔧 Sem multiplicações (lookup tables).
- 👁 Mental Images (Interpretabilidade).